



دانشگاه تهران
پردیس دانشکده‌های فنی
دانشکده مهندسی برق و کامپیوتر

گزارش تمرین سری اول درس شبکه

یلدا فروتن

۸۱۰۱۹۶۲۶۵

استاد درس

جناب آقای دکتر کلهر

پاییز ۹۸

۱.۱ طراحی یک شبکه تک‌لایه برای جداسازی دو نوع گل با روش Linear Perceptron

※ توجه شود برای کارکرد کد مربوط به این بخش لازم است فایل دیتاست توسط گوگل درایو آپلود گردد.

در این مساله یک دیتاست شامل دو فیچر طول گلبرگ و کاسبرگ برای دو نوع گل داده شده است. هدف جداسازی این دو دسته است. برای استفاده از دیتاست داده شده از کتابخانه pandas استفاده شده است.

بنابراین لازم است از دیتاست داده شده دو ستون اول به عنوان دو ورودی در نظر گرفته شوند. برای این کار ستون flower از دیتاست که نماینده خروجی شبکه میباشد، حذف شده است. ستون flower شامل اسم دو نوع گل مدنظر است. بدیهی است باید یک لیبل به نام هر گل اختصاص داده شود. برای این منظور یک ماتریس target با ابعاد 100*1 ساخته شده است که شامل لیبل‌های ۱ و -۱ است.

به دلیل وجود دو ورودی (طول گلبرگ و کاسبرگ) ماتریس وزن به صورت 2*1 و بایاس به صورت یک عدد اسکالر در نظر گرفته شده است. همچنین یک پارامتر ترشهلد برای ایجاد حاشیه امن به اندازه ۰.۱ قرار داده شده است.

$$net = w_1x_1 + \dots + w_ix_i + \dots + w_nx_n + b$$

$$(\#) \quad h = \begin{cases} 1 & \text{if } net > \theta \\ 0 & \text{if } |net| < \theta \\ -1 & \text{if } net < -\theta \end{cases} \quad \begin{matrix} \text{Active} \\ \text{non - descision} \\ \text{Passive} \end{matrix}$$

θ : non - negative threshold

طبق رابطه بالا، در ۱۰ ایپاک، مقادیر وزن در هر سطر از ماتریس ورودی ضرب شده و با بایاس جمع و با مقدار ترشهلد مقایسه شده است. سپس یک ماتریس خطا برای قدرمطلق اختلاف ماتریس target و predict ساخته شده است. حال اگر خطا برای هر سطر از ورودی مخالف صفر باشد، مقادیر w و b طبق رابطه زیر آپدیت می‌شوند.

```
w = w + alfa * x[i,:] * target[i]
b = b + alfa * target[i]
```

در این حالت مقادیر ماتریس وزن و بایاس به صورت زیر خواهد بود:

```
Weights = [[ 0.146 -0.18 ]], Bias = [0.06]
```


همانطور که پیش‌تر آمده است، در معادله net ورودی‌ها، وزن و بایاس قرار دارد. حال اگر مقادیر train شده در معادله net قرار داده شود، میتوان یک خط جداساز بین دو دسته ورودی قرار داد.

$$net = w_{0,0} \cdot x_1 + w_{0,1} \cdot x_2 + b = 0 \rightarrow x_2 = \frac{-b - w_{0,0} \cdot x_1}{w_{0,1}}$$

مقادیر به صورت یک بازه پیوسته به صورت [3.5, 8.5] داده شده است. حال با استفاده از معادله سبزرنگ، مقادیر x_2 برای این بازه محاسبه میشود. همچنین در معادله net یکبار مقدار ترشهد اضافه و بار دیگر کم شده است تا حاشیه امن نیز در شکل نهایی قابل مشاهده باشد. در نهایت سه معادله به صورت زیر نوشته شده است:

```
x1_line = np.arange(3.5,8.5)
x2_line1 = (-b - w[0,0] * x1_line)/w[0,1]
x2_line2 = (-b - w[0,0] * x1_line + threshold)/w[0,1]
x2_line3 = (-b - w[0,0] * x1_line - threshold)/w[0,1]
```


در ادامه نقاط ورودی براساس دو فیچر طول گلبرگ و کاسبرگ رسم شده و خطوط جداساز نیز قابل مشاهده است. شکل زیر برای مقدار $\text{lerning rate} = 0.6$ و $\text{threshold} = 0.3$ رسم شده است.



شکل ۱ – جداسازی دو کلاس قرمز و آبی با استفاده از شبکه پرسپترون

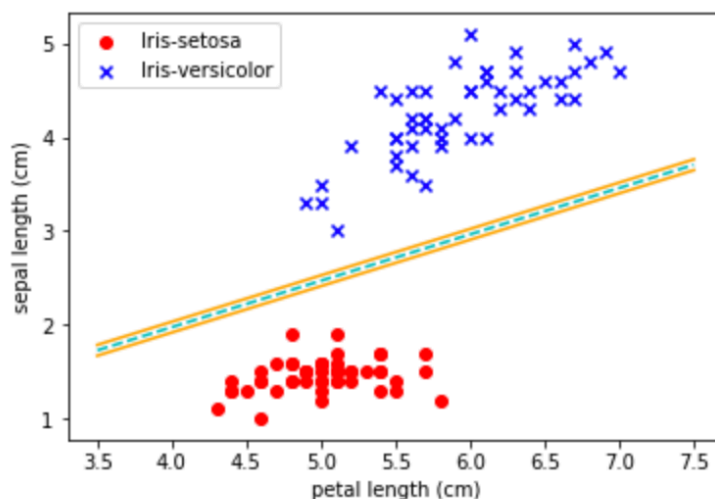
۲.۱ بررسی تاثیرات تغییرات آلفا و حذف بایاس

با کاهش آلفا ممکن است جداسازی دچار مشکل شود. مثلاً برای آلفا ۰.۰۲ جداسازی دچار اشتباه می‌شود.



شکل ۲ – جداسازی دو کلاس قرمز و آبی با استفاده از شبکه پرسپترون و اثر تغییر آلفا


همانطور که در شکل زیر قابل مشاهده است با حذف بایاس تفکیک دو کلاس دچار مشکل نمیشود. البته این موضوع بسته به مقادیر آلفا و ترشهد دارد. مثلاً برای آلفا ۰.۱ اگر بایاس حذف شود، جداسازی دچار مشکل میشود.



شکل ۳ – جداسازی دو کلاس قرمز و آبی با استفاده از شبکه پرسپترون و اثر تغییر ترشهد

۱.۳.۱ جداسازی کلاس قرمز و آبی

هدف از این بخش، جداسازی دو کلاس قرمز و آبی از یکدیگر است. لازم به ذکر است در کلاس قرمز، مختصات نقاط اشتباه است و از مختصات نقاط روی شکل استفاده شده است.



شکل ۴ - دو کلاس قرمز و آبی


در ابتدا دو کلاس براساس مختصات نقاط در نظر گرفته شد. سپس یک ماتریس بر اساس اتصال دو کلاس و توان مقادیر آنها به عنوان ماتریس ورودی ساخته شد. بدیهی است که ماتریس ورودی دارای ابعاد 10×4 است. براساس ابعاد ماتریس ورودی، مختصات و توان دو مختصات نقاط، یک بردار وزن ۴ تایی و یک بایاس در نظر گرفته شد. همچنین یک بردار target ساخته شد به گونه ای که سه درایه اول آن مربوط به نقاط قرمز است و مقدار +1 را دارند. ۷ درایه بعدی بردار target مربوط به نقاط آبی بوده و مقدار -1 به آنها اختصاص داده شده است. مقادیر ترشهلد و آلفا نیز به ترتیب ۰.۳ و ۰.۲ در نظر گرفته شده است. سپس برای هر درایه از ماتریس ورودی، بردار وزن در آن ضرب شده و با بایاس جمع شده است. در نهایت با مقدار ترشهلد مقایسه گردیده است و ماتریس predict ساخته شده است. در نهایت با قایده مربوط به پرسپترون، مقادیر وزن و بایاس آپدیت شده اند که در ادامه آمده است. لازم به ذکر است مقدار ایپاک به طور اختیاری ۲۰ انتخاب شده است.

$$\text{Weights} = [0.4 \quad -1.2 \quad 0. \quad -0.4] , \text{Bias} = -0.2$$

برای رسم خط جداکننده دو کلاس، هدف آن بود که یک بیضی دور نقاط کشده شود. بنابراین معادله مربوط به بیضی با ضرایب ماتریس وزن نوشته شد. اما در نهایت یک هذلولی کشیده شده است. به آن دلیل که معادله بیضی و هذلولی در یک ضریب منفی تفاوت دارند. معادله مربوط به هذلولی یا همان بیضی در ادامه آمده

است. برای این منظور ابتدا به متغیر x نقاطی در بازه ۰ تا ۵ اختصاص داده شده است و مقدار y طبق معادله زیر محاسبه گردیده است. در نهایت شکل زیر مشاهده شد.

$$y = \pm \sqrt{-w[0]\left(\frac{x + w[2]}{2w[0]}\right)^2 + \frac{(w[2])^2}{4w[0]} + \frac{(w[3])^2}{4w[1]} - \frac{b}{w[1]} - \frac{w[3]}{2w[0]}}$$




شکل ۵ - چگونگی جداسازی دو کلاس قرمز و آبی با هذلولی

بدیهی است اگر بازه x بیشتر مقادیر منفی را دربرگیرد، قرینه خط نارنجی قابل مشاهده خواهد بود.

۲.۳.۱ جداسازی کلاس قرمز و آبی

در این قسمت نیز هدف جداسازی نقاط قرمز از آبی است. نحوه قرار گرفتن این نقاط در شکل زیر آمده است.




شکل ۶ - دو کلاس قرمز و آبی

همانند قسمت قبل یک ماتریس از مختصات و توان آنها ساخته شده است. بدیهی است ماتریس ورودی دارای ابعاد 4×11 است. همچنین بردار target برای نقاط ساخته شده که ۳ درایه اول آن دارای مقادیر ۱ و سایر درایه ها دارای مقادیر ۰ هستند. در نهایت مقادیر وزن ها و بایاس پس از ۸۰ اپیاک به صورت زیر مشاهده شد.

Weights = [-2.2 -1.525 3.9 2.9] , Bias = -1.9999999999999998

نحوه مقداردهی برای رسم خط جداساز همانند حال قبل بود. به گونه ای که به ورودی از بازه ۰ تا ۲ مقدار داده و براساس معادله بیضی و قراردادن مقادیر وزن ها و بایاس در معادله آن، همانند حالت قبل، جداسازی به صورت زیر مشاهده گردید.



شکل ۷ - چگونگی جداسازی دو کلاس قرمز و آبی با بیضی


۱.۲ جداسازی دو کلاس با توزیع متفاوت توسط Adaline

هدف از این بخش، جداسازی دو شبکه با استفاده از روش آدالین است. برخلاف قسمت قبل، دو کلاس با اطلاعات داده شده ساخته شدند. در ادامه نحوه ساخت این دو کلاس آمده است. همچنین شکل مربوط به داده‌های تعریف شده برای دو کلاس آبی و قرمز قابل مشاهده است.

```
x1 = 2 + 0.5 * np.random.randn(100, 1)
y1 = 0 + 0.2 * np.random.randn(100, 1)
xi1 = np.concatenate((x1, y1), axis = 1)

x2 = 0 + 0.1 * np.random.randn(30, 1)
y2 = -1 + 0.7 * np.random.randn(30, 1)
xi2 = np.concatenate((x2, y2), axis = 1)

xi = np.concatenate((xi1, xi2), axis = 0)
```



شکل ۸ - دو کلاس قرمز و آبی با توزیع نامتقارن

سپس ماتریس target به صورت ۱۰۰ درایه اول با مقدار ۱ و ۳۰ درایه بعدی با مقدار -۱ ساخته شده است. بدیهی است که ماتریس ورودی یک ماتریس ۱۳۰*۲ است. بنابراین بردار وزن دارای دو ورودی است و بردار بایاس تک درایه‌ای است. در ابتدا برای هر داده، مقدار net براساس رابطه زیر محاسبه گردید و تابع sign بر آن‌ها پیاده شد.

$$net = \sum_{i=1}^n w_i x_i + b$$


$$h = f(net) = \begin{cases} +1 & net \geq 0 \\ -1 & net < 0 \end{cases}$$

سپس براساس رابطه داده شده برای خطا، در ادامه قابل مشاهده است، مقادیر وزن و بایاس آپدیت شدند. در نهایت مقادیر آپدیت شده به صورت زیر مشاهده گردید:

$$errors = \frac{1}{2} (target - net)^2$$


Weights = [3.97150706 3.15808151] , Bias = 0.8138654732616875

در نهایت نمودار خطا بر اساس اپیاک به صورت زیر شد:



شکل ۹ - نمودار خطا برحسب تعداد اپیاک

همچنین الگوریتم، جداسازی را به صورت زیر انجام داد:



شکل ۱۰ - چگونگی جداسازی دو کلاس قرمز و آبی با یک خط

۲.۲ بررسی الگوریتم Adaline برای داده‌های با توزیع نامتقارن

استفاده از روش آدلاین برای دو کلاس ساخته شده در قسمت قبل مناسب نیست. زیرا روش آدلاین تاجایی که توزیع داده‌ها متقارن است خوب عمل میکند و یک hyperplane مناسب در وسط داده‌ها قرار میدهد که فاصله قابل توجهی از هر دو کلاس دارد. اما هنگامی که توزیع کلاس‌ها یکسان نیست، ممکن است جداساز را جایی قرار دهد که حتی جداسازی را به درستی انجام ندهد. حال این یکسان نبودن توزیع میتواند به شباهت داده‌ها یا جمعیت آنها برگردد. دلیل این اتفاق آن است که می‌خواهد عمده خطای ناشی از جمعیت بیشتر را کم کند و جایی قرار بگیرد که جداساز را به سمت جمعیت بیشتر خم کند. در قسمت قبل نیز چون جمعیت یک کلاس ۳۰ و دیگری ۱۰۰ بود جداسازی به درستی انجام نشد. بنابراین استفاده از روش آدلاین برای داده‌های با توزیع متفاوت (جمعیت و یا شباهت متفاوت) نامناسب است.

در راستای بهبود آدلاین برای حذف وابستگی آن به شکل و جمعیت توزیع‌ها، در محاسبه خطا، به جای استفاده از net از h استفاده می‌شود:


$$\text{errors} = \frac{1}{2} (\text{target} - h)^2$$

اما از آنجایی که گرادین نیاز به مشتق h دارد شاید تابع sign مناسب نباشد و از توابع مشتق پذیر همانند tanh استفاده می‌شود.

۳. پیاده‌سازی گیت XNOR با استفاده از شبکه Madaline

در این بخش با استفاده از روش Madaline یک شبکه تعریف شده که میتواند عمل xor را انجام دهد. درواقع Madaline توسعه جدی‌تری از شبکه Adaline است. طبق الگوریتم MRI موجود در مرجع درس، که برای xor طراحی شده بود استفاده شده است. شبکه دارای دو لایه است. لایه اول از دو نورون W&H ساخته شده است. درواقع وزن این دو نورون و بایاس همین لایه اول باید train شود. هر نورون گفته شده یک خط می‌سازند که فضا را به سه ناحیه تقسیم میکند. دو ناحیه از این سه ناحیه متعلق به کلاس - بوده و ناحیه دیگر مربوط به کلاس + است. بنابراین در لایه دوم نیاز از نواحی هم‌کلاس، با یکدیگر جمع یا همان or شوند. به این دلیل است که در لایه دوم از یک نورون برای ساخت or استفاده شده است. البته در الگوریتم MRI به این گونه است. در الگوریتم MEII لایه مربوط به or نیز train می‌شود.

معماری شبکه طراحی شده در ادامه آمده است:



شکل ۱۱ - معماری استفاده شده برای پیاده‌سازی گیت XNOR

در ابتدا دو ورودی x_1 و x_2 با مقادیر ۱ و -۱ برای تعیین ۴ حالت مختلف، تعریف شده‌اند. یک ماتریس target به عنوان جواب xnor نیز در نظر گرفته شده است. بدیهی است xnor در حالتی که ورودی‌ها یکسان

باشند، مقدار ۱ و در غیر این صورت مقدار -۱ را دارد. یک ماتریس وزن 2×2 و یک بردار بایاس 2×1 برای لایه اول لازم است که به صورت اختیاری مقداردهی شده اند. لایه دوم به یک ماتریس وزن 2×1 و یک بایاس احتیاج دارد. البته یک ماتریس بایاس 3×1 برای دو لایه در نظر گرفته شده است. در لایه اول دو مقدار z_in1 و z_in2 با استفاده از مجموع حاصل ضرب وزن ها در هر دو ورودی ساخته شده است و علامت آنها تعیین میگردد و به عنوان ورودی لایه دوم مورد استفاده قرار می گیرند. ورودی های جدید در وزن مربوطه (۰.۵) ضرب شده و بایاس مربوطه (۰.۵) جمع شده و علامت آن محاسبه میگردد. حال مقدار خروجی شبکه با target مقایسه می شود و اگر یکسان نبود، حالت های زیر بررسی میشود:

- اگر $target = -1$ ، یعنی حداقل یکی از $z1$ یا $z2$ (علامت های z_in1 و z_in2)، $+1$ بوده است. در صورتی که باید هر دو -۱ می بودند، بنابراین هر کدام که $+1$ بوده را باید آپدیت کرد.
- اگر $target = 1$ ، یعنی $z1$ و $z2$ هر دو -۱ بودند و باید یکی از آنها $+1$ شود. هر کدام که net بزرگتر است، آپدیت می شود.


در نهایت مقادیر وزن و بایاس برای لایه اول به صورت زیر مشاهده گردید. این مقادیر برای الفا 0.69 است.

```
Weights =
[[ 1.92340564 -1.94108215]
 [ 2.17888506 -2.22584675]]
Bias =
[[-2.40436623]
 [-2.66978769]]
```

سپس معادله مربوط به دو خط جداکننده با استفاده از ضرایب وزن و بایاس رسم شد. یکی از ورودی ها در بازه -۲ تا ۳ مقداردهی شد. در ادامه معادله این دو خطوط آمده است.

```
x1_line = np.arange(-2, 3)
x2_line1 = (-b[0,0] - w[0,0] * x1_line)/w[1,0]
x2_line2 = (-b[1,0] - w[0,1] * x1_line)/w[1,1]
```


در نهایت دو خط جداساز به صورت شکل زیر عمل طبقه‌بندی را انجام دادند. بدیهی است بین خطوط مربوط به کلاس +۱ و در طرفین مربوط به کلاس -۱ است.



شکل ۱۲ - چگونگی عملکرد گیت XNOR با دو خط

۴ - طراحی یک شبکه عصبی برای جداسازی درون و بیرون یک چهارضلعی محدب

طبق صورت مساله، باید امکان جداسازی درون و بیرون یک چهارضلعی محدب، در اینجا دوزنقه، با استفاده از نورون‌های Mcculloch Pitts فراهم شود. این کار توسط دو لایه صورت گرفته است. در لایه اول با استفاده از هر دو نقطه مجاور معادله یک خط نوشته میشود، که در ادامه آمده است. حال با استفاده از ضرایب x و y در معادله هر خط، دو بردار وزن مربوط به x و y ساخته میشود. بدیهی است که مقادیر ثابت همان بایاس هستند. بنابراین دو بردار وزن و یک بردار بایاس با ابعاد 4×1 ساخته شده است. درواقع از هر نورون M&P برای رسم یک خط استفاده شده است. لازم به ذکر است که ماتریس‌های وزن، یک ماتریس با ابعاد 4×2 است که ستون اول برای ورودی x و ستون دوم برای ورودی y در نظر گرفته شده است. اما در محاسبات برای راحتی از دو ماتریس w_x و w_y استفاده شده است.



شکل ۱۳ - معماری شبکه برای تفکیک درون و بیرون یک چهارضلعی محدب

در لایه دوم، با استفاده از یک نورون M&P یک گیت and چهار ورودی طراحی شده است. حال میتوان دو کار کرد. معادله خط را مساوی صفر قرار داد و مقدار بایاس‌ها را با سایر ترم‌ها جمع کرد و عمل sign را بر روی معادله پیاده کرد و یا ترم بایاس به عنوان ترشهد استفاده شود. در اینجا بایاس در معادله مربوط به خطوط به کار رفته و در نهایت net با صفر مقایسه شده است. بدیهی است مقدار بایاس‌ها برای گیت and، همان تعداد ورودی‌ها خواهد بود یعنی در اینجا ۴ است.

مجموع حاصل ضرب‌های بردار وزن هر ورودی در بردار ورودی مربوطه محاسبه شده است و با بردار بایاس جمع شده است.

در لایه دوم یک بردار وزن 4×1 با مقادیر یک و بایاس -4 در نظر گرفته شده است. بدیهی است در این لایه، خروجی لایه قبل به عنوان ورودی است.

همچنین میتوان از سه لایه استفاده کرد به گونه ای که از چهار خروجی لایه اول، هر دو خروجی را به عنوان ورودی های نورون های M&P برای ساخت یک and استفاده کرد و در لایه سوم یک and دیگر استفاده کرد.

در ادامه جدول مربوط به ضرایب برای دو لایه آمده است.

جدول ۱ – مقادیر وزن ها و بایاس برای دو لایه شبکه

Line		Layer 1			Layer 2	
		w_x	w_y	b	w_and	b_and
$y-2=0$	below	0	1	-2	1	-4
$y+4x-14=0$	below	4	1	-14	1	
$y+2=0$	abow	0	1	2	1	
$y-4x-2=0$	below	-4	1	-2	1	

همچنین ۱۴ نقطه برای تست الگوریتم داده شده است. در صورتی که نقاط درون نوزنقه باشند، به رنگ آبی نشان داده می شوند و اگر خارج از چهارضلعی باشند، به رنگ قرمز درمی آیند.

```

#inside
input_( 1, 1)
input_( 3,-1.5)
input_( 1, 1.5)
input_( 0, 0)
input_( 2, 1.5)
input_( 2, 2)
input_( 0, 1)
#outside
input_(4 ,-2.1)
input_(-2, 0)
input_(-3, 0)
input_(-1, 0.5)
input_(4 , 2)
input_(5 , -1)
input_(4.5,1.5)

plt.show()


```

```

( 1 , 1 ) IS inside of the convex polygon.
( 3 , -1.5 ) IS inside of the convex polygon.
( 1 , 1.5 ) IS inside of the convex polygon.
( 0 , 0 ) IS inside of the convex polygon.
( 2 , 1.5 ) IS inside of the convex polygon.
( 2 , 2 ) IS inside of the convex polygon.
( 0 , 1 ) IS inside of the convex polygon.
( 4 , -2.1 ) ISN'T inside of the convex polygon.
( -2 , 0 ) ISN'T inside of the convex polygon.
( -3 , 0 ) ISN'T inside of the convex polygon.
( -1 , 0.5 ) ISN'T inside of the convex polygon.
( 4 , 2 ) ISN'T inside of the convex polygon.
( 5 , -1 ) ISN'T inside of the convex polygon.
( 4.5 , 1.5 ) ISN'T inside of the convex polygon.

```

شکل ۱۴ – مقادیر استفاده شده برای آزمودن شبکه



شکل ۱۵ - نحوه جداسازی درون و برون یک چهارضلعی محدب

Codes

1.1.

```
[1] #upload csv file from google drive
import pandas as pd
url = '/content/HW1_Q1_data.csv'
dataset = pd.read_csv(url)

#dataset

[2] import numpy as np
x = dataset.drop(columns = 'flower')
x = x.values
y = dataset['flower'].values

#x.shape, x, y

[ ] target = np.where(y == 'Iris-setosa', 1, -1)
target = np.reshape(target, (100,1))

#target.shape, target

[ ] import numpy as np
w = np.zeros([1, 2])
b = 0
threshold = 0.3
alfa = 0.2
predict = np.zeros([100, 1])
net = np.zeros([100, 1])
epochs = 0
errors = np.zeros([100,1])

w,b

[ ] i=0
for epochs in range (10):
    for i in range(100):
        net = np.matmul(w, x[i,:]) + b
        if net > threshold:
            predict = 1
        elif net < threshold:
            predict = -1
        else:
            predict = 0
        errors[i] = abs(predict-target[i])
        if errors[i]!=0:
            w = w + alfa * x[i,:] * target[i]
            b = b + alfa * target[i]

    print("Weights = ",w," , Bias = ",b)

[ ] x1_line = np.arange(3.5,8.5)
x2_line1 = (-b - w[0,0] * x1_line)/w[0,1]
x2_line2 = (-b - w[0,0] * x1_line + threshold)/w[0,1]
x2_line3 = (-b - w[0,0] * x1_line - threshold)/w[0,1]

#x1_line

import matplotlib.pyplot as plt
plt.scatter(x[:50, 0], x[:50, 1], color='red', marker='o', label='Iris-setosa')
plt.scatter(x[50:100, 0], x[50:100, 1], color='blue', marker='x', label='Iris-versicolor')
plt.plot(x1_line,x2_line1,'c--')
plt.plot(x1_line,x2_line2,'orange')
plt.plot(x1_line,x2_line3,'orange')
plt.xlabel('petal length (cm)')
plt.ylabel('sepal length (cm)')
plt.legend(loc='upper left')
plt.show()
```

1.3.1.

```
hw1_part1_c1.ipynb - Colaboratory
class2 = np.array([[0, 0], [1, 1], [2, 2], [3, 3], [1, -1], [2, -2], [3, -3]])
#class1.shape, class2.shape
```

```
[ ] x_class = np.concatenate((class1,class2),axis=0)
x_power = np.power(x_class,2)
x = np.concatenate((x_power, x_class),axis=1)
#x.shape, x.shape
```


```
[ ] w = np.zeros(4)
b = 0
target = np.array([1, 1, 1, -1, -1, -1, -1, -1, -1])
threshold = 0.3
alfa = 0.2
epochs = 0
for epochs in range(20):
    for i in range(0, 10, 1):
        net = np.matmul(w, x[i]) + b
        if net > threshold:
            predict = 1
        elif net < threshold:
            predict = -1
        else:
            predict = 0
        if predict != target[i]:
            for j in range(0,4,1):
                w[j] = w[j] + alfa * target[i] * x[i,j]
            b = b + alfa * target[i]
print("Weights = ",w," , Bias = ",b)
```

Weights = [0.4 -1.2 0. -0.4] , Bias = -0.2

```
import matplotlib.pyplot as plt

plt.plot(x[target == 1, 2], x[target == 1, 3], 'ro')
plt.plot(x[target == -1, 2], x[target == -1, 3], 'bo')

x_line = np.linspace(0,5,50000)
delta = (-w[0]*np.power(x_line+w[2]/(2*w[0]),2)+ np.power(w[2],2)/(4*w[0]) + np.power(w[3],2)/(4*w[1]) - b)/w[1]
x_line = x_line[delta > 0]
delta = delta [delta > 0]
y_line_p = np.sqrt(delta) - w[3]/(2*w[1])
y_line_n = -np.sqrt(delta) - w[3]/(2*w[1])
plt.plot(x_line, y_line_p, 'orange')
plt.plot(x_line, y_line_n, 'orange')
plt.show()
```



1.3.2.

```
import numpy as np
class1 = np.array([[0.75, 0.75], [1, 1], [1.25, 1.5]])
class2 = np.array([[0, 1], [0.25, 1.75], [1, 2], [1.75, 1.75], [2, 1], [1.75, 0], [1, 0], [0.25, 0.25]])

#class1.shape, class2.shape

x_class = np.concatenate((class1, class2), axis=0)
x_power = np.power(x_class, 2)
x = np.concatenate((x_power, x_class), axis=1)

#x_class, x_power
#x.shape, x

w = np.zeros(4)
target = np.array([1, 1, 1, -1, -1, -1, -1, -1, -1, -1])
b = 0
threshold = 0.1
alfa = 0.2
epochs = 0
for epochs in range(80):
    for i in range(0, 11, 1):
        net = np.matmul(w, x[i]) + b
        if net > threshold:
            predict = 1
        elif net < threshold:
            predict = -1
        else:
            predict = 0
        if predict != target[i]:
            for j in range(0, 4, 1):
                w[j] = w[j] + alfa * target[i] * x[i, j]
            b = b + alfa * target[i]
print("Weights = ", w, ", Bias = ", b)

import matplotlib.pyplot as plt
plt.plot(x[target == 1, 2], x[target == 1, 3], 'ro')
plt.plot(x[target == -1, 2], x[target == -1, 3], 'bo')

x_line = np.linspace(0, 2, 50000)
delta = (-w[0]*np.power(x_line+w[2]/(2*w[0]), 2) + np.power(w[2], 2)/(4*w[0]) + np.power(w[3], 2)/(4*w[1]) - b)/w[1]
x_line = x_line[delta > 0]
delta = delta[delta > 0]
y_line_p = np.sqrt(delta) - w[3]/(2*w[1])
y_line_n = -np.sqrt(delta) - w[3]/(2*w[1])
plt.plot(x_line, y_line_p, 'orange')
plt.plot(x_line, y_line_n, 'orange')
plt.show()
```

2.

```
[262] import numpy as np

x1 = 2 + 0.5 * np.random.randn(100, 1)
y1 = 0 + 0.2 * np.random.randn(100, 1)
xi1 = np.concatenate((x1, y1), axis = 1)

x2 = 0 + 0.1 * np.random.randn(30, 1)
y2 = -1 + 0.7 * np.random.randn(30, 1)
xi2 = np.concatenate((x2, y2), axis = 1)

xi = np.concatenate((xi1, xi2), axis = 0)

target = np.concatenate((np.ones((1, 100)), -1*np.ones((1, 30))), axis=1)
target = np.squeeze(target)

#xi.shape
#xi1, xi2 ,xi
#target.shape, target
```

```
[263] w = np.zeros(2)
b = 0
alfa = 0.09
errors = np.zeros((130))

#w, wp, b, alfa, errors
```

```
[264] for epochs in range (0,130,1):
    for i in range(0, 130, 1):
        net = np.matmul(w, xi[i]) + b
        errors[i] = 0.5 * ((target[i] - net)**2)
        for j in range(0, 2, 1):
            w[j] = w[j] + alfa * (target[i] - net)*xi[i, j]
        b = b + alfa * target[i] - net

    print("Weights = ",w," , Bias = ",b)
```

```
[266] import matplotlib.pyplot as plt
epochs = np.arange(1,131)
plt.figure(0)
plt.plot(epochs, errors, 'cyan')
plt.xlabel('Epochs')
plt.ylabel('Errors')
plt.show()
```

```
▶ x_line = np.arange(-0.5, 2)
y_line = (-b - w[0] * x_line)/w[1]
plt.figure(1)
plt.plot(xi[target == -1, 0], xi[target == -1, 1], 'ro')
plt.plot(xi[target == 1, 0], xi[target == 1, 1], 'bo')
plt.xlabel('x')
plt.ylabel('y')
plt.plot(x_line, y_line, 'green')
plt.show()
```

3.

```

import numpy as np

x1 = np.array([1, 1, -1, -1])
x2 = np.array([1, -1, 1, -1])

target = np.array([1, -1, -1, 1])

v = np.array([[0.5],[0.5]])
b = np.array([[0.3],[0.15],[0.5]])
w = np.array([[0.05,0.1],[0.2,0.2]])

alfa = 0.69

[52] def sign(x):
    if x >= 0:
        yt = 1
    else:
        yt = -1
    return(yt)

[53] flag = True
    epoch = 0
    while(flag):
        flag = False
        for i in range (0,4):
            z_in1 = x1[i] * w[0,0] + x2[i] * w[1,0] + b[0,0]
            z_in2 = x1[i] * w[0,1] + x2[i] * w[1,1] + b[1,0]
            z1 = sign(z_in1)
            z2 = sign(z_in2)
            y_in = v[0,0] * z1 + v[1,0] * z2 + b[2,0]
            y = sign(y_in)
            if (-target[i]+y) == 0:
                error=0
            else:
                if target[i] == -1:
                    if z_in1>0:
                        b[0,0] = b[0,0] + alfa*(-1-z_in1)
                        w[0,0] = w[0,0] + alfa*(-1-z_in1)*x1[i]
                        w[1,0] = w[1,0] + alfa*(-1-z_in1)*x2[i]
                    if z_in2>0 :
                        b[1,0] = b[1,0] + alfa*(-1-z_in2)
                        w[0,1] = w[0,1] + alfa*(-1-z_in2)*x1[i]
                        w[1,1] = w[1,1] + alfa*(-1-z_in2)*x2[i]

                    #flag = True
                if target[i] == 1:
                    if abs(z_in1)<abs(z_in2):
                        b[0,0] = b[0,0] + alfa*(1-z_in1)
                        w[0,0] = w[0,0] + alfa*(1-z_in1)*x1[i]
                        w[1,0] = w[1,0] + alfa*(1-z_in1)*x2[i]
                    else:
                        b[1,0] = b[1,0] + alfa*(1-z_in2)
                        w[0,1] = w[0,1] + alfa*(1-z_in2)*x1[i]
                        w[1,1] = w[1,1] + alfa*(1-z_in2)*x2[i]
                    flag = True
                epoch = epoch + 1

        print("Weights = ")
        print(w)
        print("Bias =" )
        print(b[0:2])

[54] x1_line = np.arange(-2, 3)
    x2_line1 = (-b[0,0] - w[0,0] * x1_line)/w[1,0]
    x2_line2 = (-b[1,0] - w[0,1] * x1_line)/w[1,1]

[55] import matplotlib.pyplot as plt
    plt.scatter(x1, x2, color='red', marker='o')
    plt.plot(x1_line,x2_line1,'b')
    plt.plot(x1_line,x2_line2,'g')
    plt.xlabel('x1')
    plt.ylabel('x2')
    #plt.xlim(-1,0.5)
    plt.grid()
    plt.show()

```


4.

```
| import numpy as np

x = np.array([ 0, 3, 4, -1])
y = np.array([ 2, 2, -2, -2])

w_x = np.array([ 0, 4, 0, -4])
w_y = np.array([ 1, 1, 1, 1])
b = np.array([-2, -14, 2, -2])

w_and = np.ones(4)
b_and = -4

| def line(x, y, w_x, w_y, b):
    net = w_x * x + w_y * y + b
    if net <= 0:
        return True
    else:
        return False

def convex(x, y):
    a_line = line(x, y, w_x[0], w_y[0], b[0])
    b_line = line(x, y, w_x[1], w_y[1], b[1])
    c_line = line(x, y, -w_x[2], -w_y[2], -b[2])
    d_line = line(x, y, w_x[3], w_y[3], b[3])

    out = a_line + b_line + c_line + d_line + b_and
    if out >= 0:
        return True
    else:
        return False

| def input_(a, b):
    if convex(a, b)==True:
        print("(a,b)", "IS inside of the convex polygon.")
        plt.plot(a, b, 'bo')
    else:
        print("(a,b)", "ISN'T inside of the convex polygon.")
        plt.plot(a, b, 'ro')

import matplotlib.pyplot as plt

x_line1 = np.linspace( 0, 3, 500)
y_line1 = np.linspace( 2, 2, 500)
plt.plot(x_line1, y_line1, 'blue')

x_line2 = np.linspace( 3, 4, 500)
y_line2 = np.linspace( 2, -2, 500)
plt.plot(x_line2, y_line2, 'blue')

x_line3 = np.linspace( 4, -1, 500)
y_line3 = np.linspace(-2, -2, 500)
plt.plot(x_line3, y_line3, 'blue')

x_line4 = np.linspace(-1, 0, 500)
y_line4 = np.linspace(-2, 2, 500)
plt.plot(x_line4, y_line4, 'blue')
plt.xlabel('x')
plt.ylabel('y')

#inside
input_( 1, 1)
input_( 3,-1.5)
input_( 1, 1.5)
input_( 0, 0)
input_( 2, 1.5)
input_( 2, 2)
input_( 0, 1)
#outside
input_(4,-2.1)
input_(-2, 0)
input_(-3, 0)
input_(-1, 0.5)
input_(4, 2)
input_(5, -1)
input_(4.5,1.5)

plt.show()
```